

Computing methods project

Gianluca Morcaldi

1 luglio 2026

Sommario

Questo progetto contiene l'implementazione di un algoritmo di segmentazione basato su U-Net per la segmentazione automatica di masse in mammografia.


1 Pre-elaborazione

Il lavoro è stato sviluppato partendo dai dati contenuti all'interno del dataset CBIS-DDSM. Questo dataset è una versione curata del dataset DDSM, e mette a disposizione mammografia e maschere di segmentazione di masse e calcificazioni mammarie, in formato DICOM. Per entrambe sono fornite sia la proiezione Medio-Latero Obliqua (MLO), che la proiezione Cranio-Caudale (CC). Per questo studio sono state prese in considerazione esclusivamente le masse mammarie e la proiezione MLO.


Successivamente sono state progettate e valutate due pipeline di preprocessing a cui ogni mammografia è stata sottoposta. In Figura 1a è mostrata l'applicazione di un filtro mediano, Contrast Limited Adaptive Histogram Equalization (CLAHE) e unsharp masking, mentre in Figura 1b l'applicazione di CLAHE viene sostituita con l'equalizzazione dell'istogramma.

Basandosi sulla qualità percepita dell'immagine finale, si è scelto di usare la pipeline con CLAHE mostrata in Figura 1a. Questo in quanto l'equalizzazione dell'istogramma tende a creare delle zone troppo chiare o troppo scure sull'immagine, impedendo di apprezzare i dettagli morfologici.

Infine, sia l'immagine che la maschera di riferimento vengono ritagliate attorno alla lesione; il ritaglio non è netto, ma include anche 20 pixel di padding in ogni direzione per poter catturare un contorno maggiore attorno la lesione. L'immagine e la maschera di riferimento sono quindi ridimensionate, portandole a una dimensione pari a 512×512 pixels.



(a) Applicazione in ordine di un filtro mediano, CLAHE e unsharp masking.



(b) Applicazione in ordine di un filtro mediano, equalizzazione dell'istogramma e unsharp masking.

Figura 1: Esempio di applicazione del preprocessing su una mammografia, al fine di migliorarne le caratteristiche visive.

2 Architettura del modello

Il modello è stato sviluppato implementando l'architettura U-Net, con alcune modifiche rispetto all'implementazione originale, poiché l'implementazione adottata non utilizza ritaglio (cropping) e zero padding, preservando così le dimensioni spaziali tra input e output.

3 Strategia di addestramento e validazione

Il dataset è stato suddiviso nei set di training, validation e test secondo una proporzione 70-20-10. Questo ha portato ad avere rispettivamente 611, 173 e 88 masse nei tre insiemi.

Per incrementare la variabilità dei dati forniti al modello e migliorarne la capacità di generalizzazione, le immagini sono state soggette ad un processo di data augmentation. In particolare, le immagini (e le relative maschere) sono state soggette a ribaltamenti (orizzontali e verticali) e rotazioni.

Per l'ottimizzazione degli iperparametri, i modelli sono stati addestrati sul training set e valutati sul validation set. È stato scelto il framework Optuna per la loro ottimizzazione. Inoltre, l'addestramento dei modelli include l'uso dell'arresto anticipato (Early Stopping) per interrompere l'addestramento del modello nel caso in cui l'errore di validazione non migliori oltre una certa soglia per un certo numero consecutivo di epoche. Questo al fine di velocizzare l'allenamento interrompendo anticipatamente quei modelli con prestazioni stagnanti.

Una volta individuata la combinazione ottimale di iperparametri, definita come quella associata al valore minimo della loss sul validation set, viene addestrato un nuovo modello utilizzando tali parametri. I set di addestramento e di validazione sono quindi uniti per massimizzare la quantità di dati disponibili per l'apprendimento e il modello finale è quindi valutato sul test set.

Come funzioni di loss sono state implementate Dice, Jaccard e Binary Cross Entropy (BCE).

4 Risultati

Come configurazione iniziale dell'esperimento sono state impostate un massimo di 80 epoche, la Dice Loss come funzione di perdita, un parametro di patience pari a 5 e un valore di minimum delta pari a 0.0007 per il meccanismo di early stopping. Per l'ottimizzazione degli iperparametri tramite Optuna sono stati eseguiti 40 tentativi.

Gli iperparametri sottoposti a ottimizzazione sono stati la dimensione del batch, con valori possibili pari a 2, 4, 8 e 16 (quest'ultimo scelto come limite superiore per evitare l'occupazione completa della memoria disponibile da parte di un singolo batch), e il learning rate, campionato nell'intervallo compreso tra 0.001 e 0.1.

Il miglior risultato sul validation set è stato ottenuto con un learning rate di 0.016 e una dimensione del batch pari a 8. Il modello è stato addestrato per 32 epoche, prima che entrasse in funzione il meccanismo di early stopping, e l'andamento della loss sul training set e sul validation set è riportato in Figura 2.




Figura 2: Training e validation loss, in 32 epoche, del miglior modello ottenuto tramite ottimizzazione degli iperparametri.

Successivamente, un nuovo modello è stato creato con questi iperparametri e addestrato sull'unione di training e validation set, presentando un andamento della curva di perdita mostrato in Figura 3. Il modello è stato quindi valutato sul test set, ottenendo una dice loss di 0.37. In Figura 4 è possibile osservare due campioni appartenenti al test set, con relativa maschera di segmentazione originale e prodotta dalla rete neurale. Quello che appare è che la rete sia orientata verso la segmentazione delle aree marcatamente distaccate dallo sfondo, generalmente più chiare da un punto di vista visivo. Se da una parte questa interpretazione suggerisce che il modello sia in grado di individuare aree visivamente separate dallo sfondo, dall'altra non è possibile determinare con certezza quanto questo aspetto sia clinicamente rilevante e quali siano gli elementi visivi e morfologici effettivamente considerati.




Figura 3: Training loss del modello allenato su training e validation set, utilizzando i miglior iperparametri trovati.




Figura 4: Due mammografie appartenenti al test set, con relativa maschera di segmentazione ground truth e maschera prodotta dalla rete neurale.